Rozproszona baza danych

Dokumentacja projektu

Piotr Kalański, Marcin Kubacki, Marek Kurdej, Adrian Wiśniewski

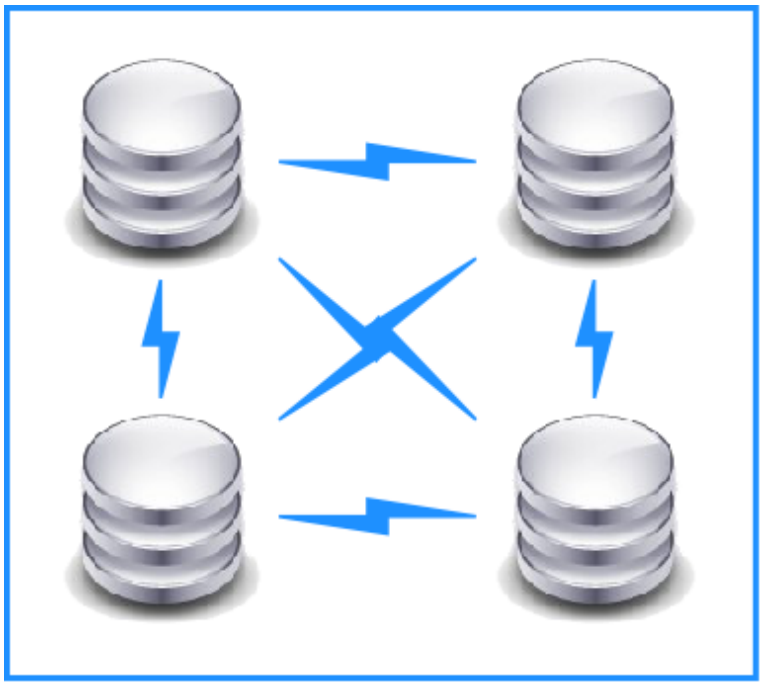

Spis treści

Rozdział 1

Wprowadzenie

Obecnie redundancja w systemach bazodanowych jest koniecznością. Zabezpiecza ona przed utratą danych, gdyby z pewnych powodów pojedynczy węzeł odmówił posłuszeństwa. Rozwiązaniem typowym w środowiskach produkcyjnych jest klaster wysokiej dostępności (ang. emphHigh Availability Cluster), który powiela transakcje na poszczególnych węzłach.

Tematem projektu było stworzenie rozproszonej bazy danych, a właściwie klastra wysokiej dostępności, która umożliwiałaby wykonywanie zapytań na dowolnym węźle, a następnie automatyczną synchronizację takiej operacji na pozostałe węzły bazy. Dodatkowo w przypadku uruchomienia nowego węzła, węzeł ten powinien móc zsynchronizować się z pozostałymi węzłami.

Ze względu na ograniczenia czasowe rozwiązanie zostanie przedstawione na 2 implementacjach zamiast 4, pierwszej napisanej w języku Java oraz drugiej w .NET. Trzecia implementacja w Qt nie funkcjonowała poprawnie, więc zostanie wykluczona z dalszych rozważań.

Kluczowymi algorytmami rozproszonymi dla tego projetu były:

- trójfazowe zatwierdzanie transakcji (ang. *Three Phase Commit*)
- autorski pomysł synchronizacji dynamicznie dołączanych węzłów

Oba algorytmy zostaną szczegółowo omówione w dalszej części dokumentacji. Dodatkowo, aby łatwiej można było wgłębić się w niektóre części kodu - przedstawiono również diagramy sekwencji.

Rozdział 2

Architektura

Całe rozwiązanie składa się z kilku części. Ogólnie podzielić projekt można na następujące warstwy:

- komunikacyjną
- logiki aplikacyjnej
- dostępu do danych

2.1 Warstwa komunikacyjna

W skład warstwy komunikacyjnej wchodzą klasy służące do nasłuchiwania na wybranym porcie TCP i UDP. Nasłuchiwanie na porcie TCP potrzebne jest do odbierania dowolnych komunikatów obsługujących transakcje, natomiast UDP używany jest w celu odbierania tzw. "heartbeats", czyli komunikatów wysyłanych w regularnych odstępach przez wszystkie węzły w celu ogłaszania wszystkim zainteresowanym, że dany węzeł jest dostępny. Po odebraniu żądania połączenia tworzona jest obiekt klasy roboczej - TCP Worker, który zajmuje się odbieraniem pakietów i składaniem wiadomości w całość. Następnie każdy z wątków zajmujący się takimi połączeniem przekazuje wiadomość do Dispatcher'a.

Ostatecznie po przetworzeniu wiadomości musi nastąpić pewna reakcja obiawiająca się wysłaniem konkretnego pakietu. I tu używane są klasy TCP i UDP sender, które wysyłają wcześniej przygotowaną wiadomość. Tu warto jeszcze wspomnieć o Hello generatorze, który okresowo wysyła heartbeats (i tylko on korzysta z protokołu UDP). Ważny jest tu TCP sender, który przechowuje pulę połączeń, ewentualnie nawiązuje nowe.

2.2 Warstwa logiki aplikacyjnej

Dispatcher odpowiada za klasyfikację wiadomości i odpowiednią reakcję. Reakcja ta obiawia się utworzeniem odpowiedniej klasy roboczej, która będzie odpowiadała za przechodzenie po grafie stanów automatu trójfazowego zatwierdzania transakcji, lub synchronizacji węzłów. W zależności od tego, czy węzeł w danym momencie koordynuje transakcję, czy realizuje polecenia z innych węzłów tworzone są instancje obiektów Cohort lub Coordinator - podobnie dla synchronizacji (przedrostek Restore). W obu przypadkach użyto wzorca projektowego „Stan".

Każda z klas nadzorująca daną sesję, kontroluje czas spędzony w oczekiwaniu i ewentualnie powiadamia o upłynięciu limitu czasu na odpowiedź.

2.3 Warstwa dostępu do danych

W tej warstwie znajdują się wszelkie klasy, które mają na celu manipulować właściwymi danymi przechowywanymi w bazie. Klasą, która po części jest logiką aplikacyjną jest Database state. Ma ona na celu przechowywać aktualne blokady i stan bazy danych. Oprócz tego występują dwie inne pomocnicze klasy - Database connector i SQL parser, które mają na celu parsować i zapytania i umożliwiać dialog z właściwą bazą danych.

Każde z zapytań jest wstępnie iterpretowane przez SQL parsera, a następnie w zależności od zapytania, klasy cohort'ów wykonują odpowiednie akcje, jak np. blokowanie bazy. Podczas parsowania zapytania oprócz tabeli i rodzaju zapytania generowane jest również zapytanie uwzględniające dodatkowową kolumnę dla blokowania wierszy. Każde zapytanie wykonuje się odpowiednio zmodyfikowane o tą właśnie kolumne. Tu czynione jest założenie, że baza danych jest wstępnie założona i przygotowana do nawiązywania połączeń przez węzeł, na którym się znajduje.

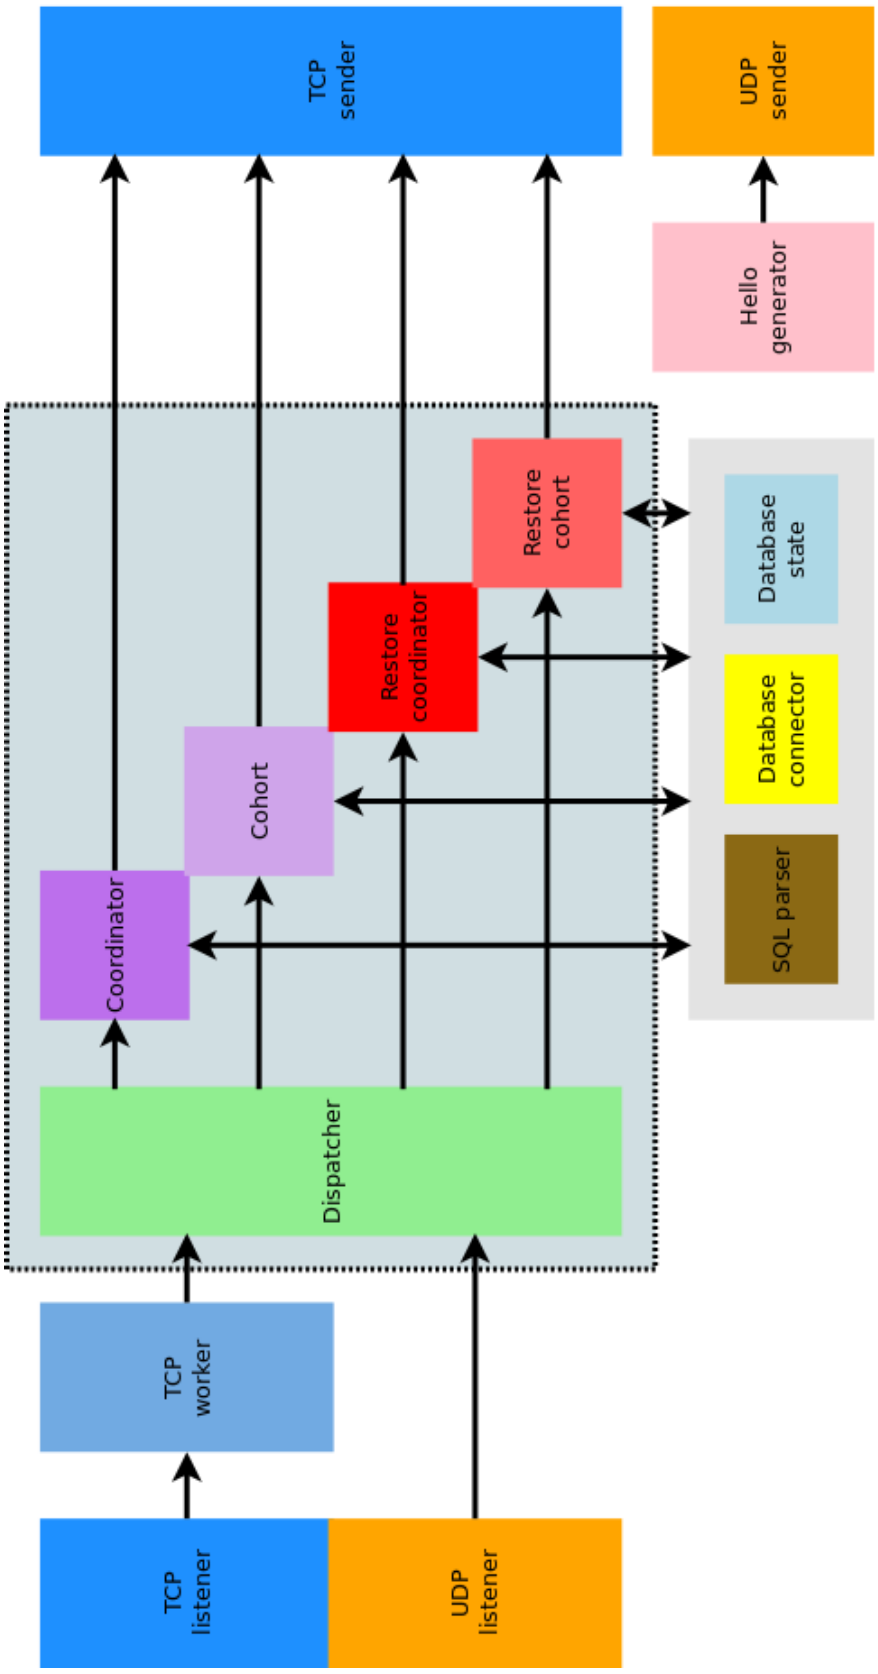

Rysunek 2.1: Architektura rozwiązania

Rozdział 3

Trójfazowe zatwierdzanie transakcji

Główną częścią logiki systemu będzie trójfazowe zatwierdzanie transakcji, które umożliwi wykonanie pojedynczej transakcji na wszystkich lub na żadnym węźle. Poniżej opis protokołu.

3.1 Model automatowy

Serwer (Coordinator)

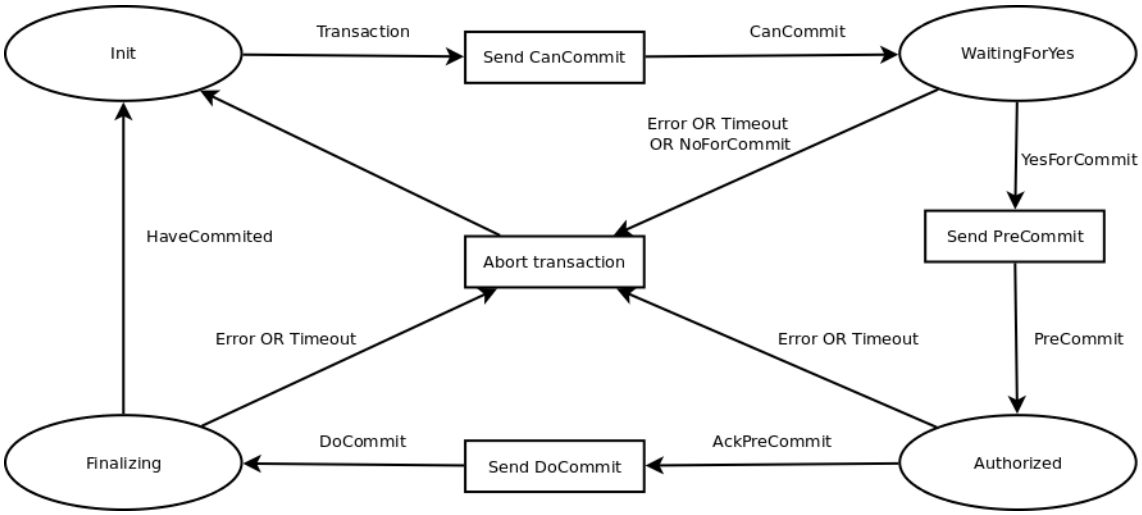

Klient (Cohort)

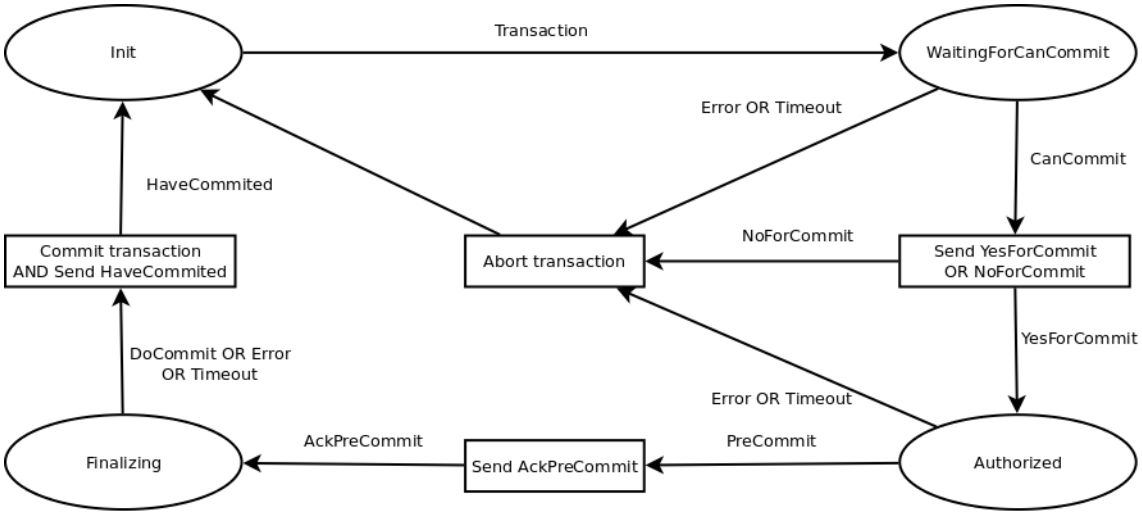

3.2 Opis słowny

Zatwierdzanie trójfazowe jest rozproszonym algorytmem, który nakazuje węzłą w rozproszonym systemie uzgodnić fakt zatwierdzania transakcji. W przeciwieństwie do swojego dwufazowego poprzednika, wersja trójfazowa jest nieblokująca.

Serwer (Coordinator)

1. Pewien klient inicjuje sekwencję trójfazowego zatwierdzenia za pomocą pakietu `Transaction`. W razie problemu transakcja jest anulowana. Koordynator wysyła zapytanie do klientów, czy chcą zatwierdzić (`CanCommit`) i przechodzi do stanu oczekiwania.

2. W przypadku odpowiedzi pozytywnej wysyła do wszystkich wiadomość `PreCommit`, który nakazuje stacjom klienckim przygotować się do zatwierdzenia. W razie błędu, upłynięcia limitu czasu dla którejś ze stacji lub odebrania od dowolnego klienta `NoForCommit` - transakacja jest anulowana. W przeciwnym wypadku następuje trzecia faza

3. W trzeciej fazie kordynator wysyła `DoCommit`, który ostatecznie nakazuje klientom zatwierdzić lub odrzucić daną transakcję. Gdyby w którejś fazie nie dotarł pakiet - klient lub serwer odczekują określony czas i ewentualnie anulują transakcję.

Klient (Cohort)

1. Klient dostaje zapytanie, czy chce zatwierdzić transakcję i odpowiada twierdząco (komunikat `YesForCommit`) i przechodzi do stanu przygotowania, ewentualnie odpowiada, że chce transakcję odrzucić (komunikat `NoForCommit`).

2. W stanie przygotowania, jeśli dostanie komunikat o anulowaniu lub minie timeout, transakcja jest anulowana. Jeśli otrzyma komunikat `PreCommit` potwierdza go komunikatem `AckPreCommit`.

3. Po odebraniu komunikatu `DoCommit` transakcja jest zatwierdzana (i wysyłany jest komunikat `HaveCommitted`), w przeciwnym wypadku (błąd lub upłynięcie timeoutu transakcja jest anulowana).

Rozdział 4

Dynamiczne dodawanie nowych węzłów

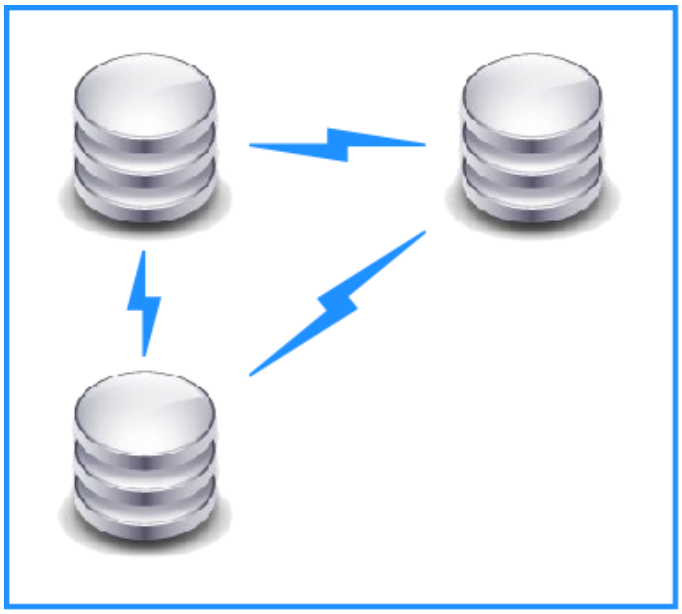

Rysunek 4.1: Początkowa faza - 3 węzły działające

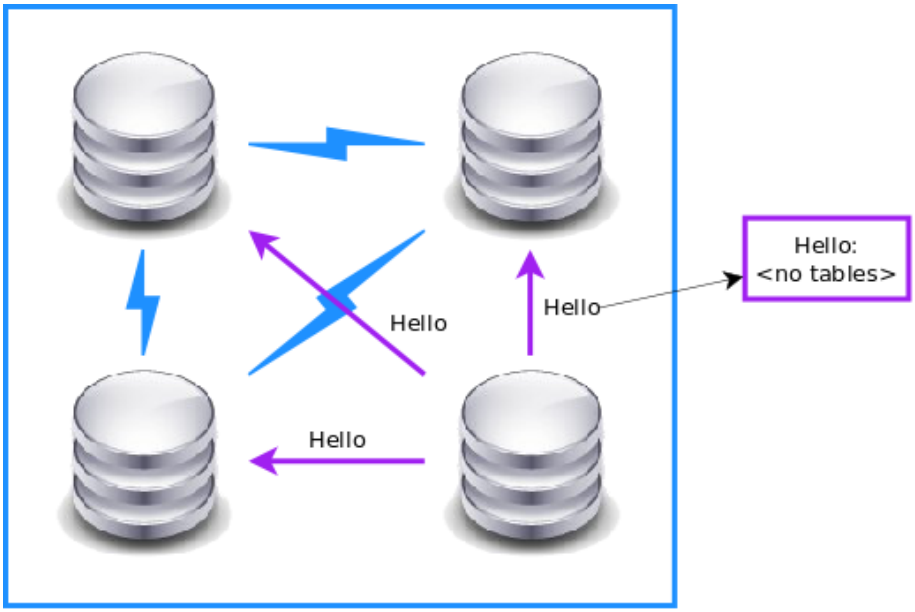

Rysunek 4.2: Nowo dodany węzeł zaczyna rozgłaszać swoje Hello

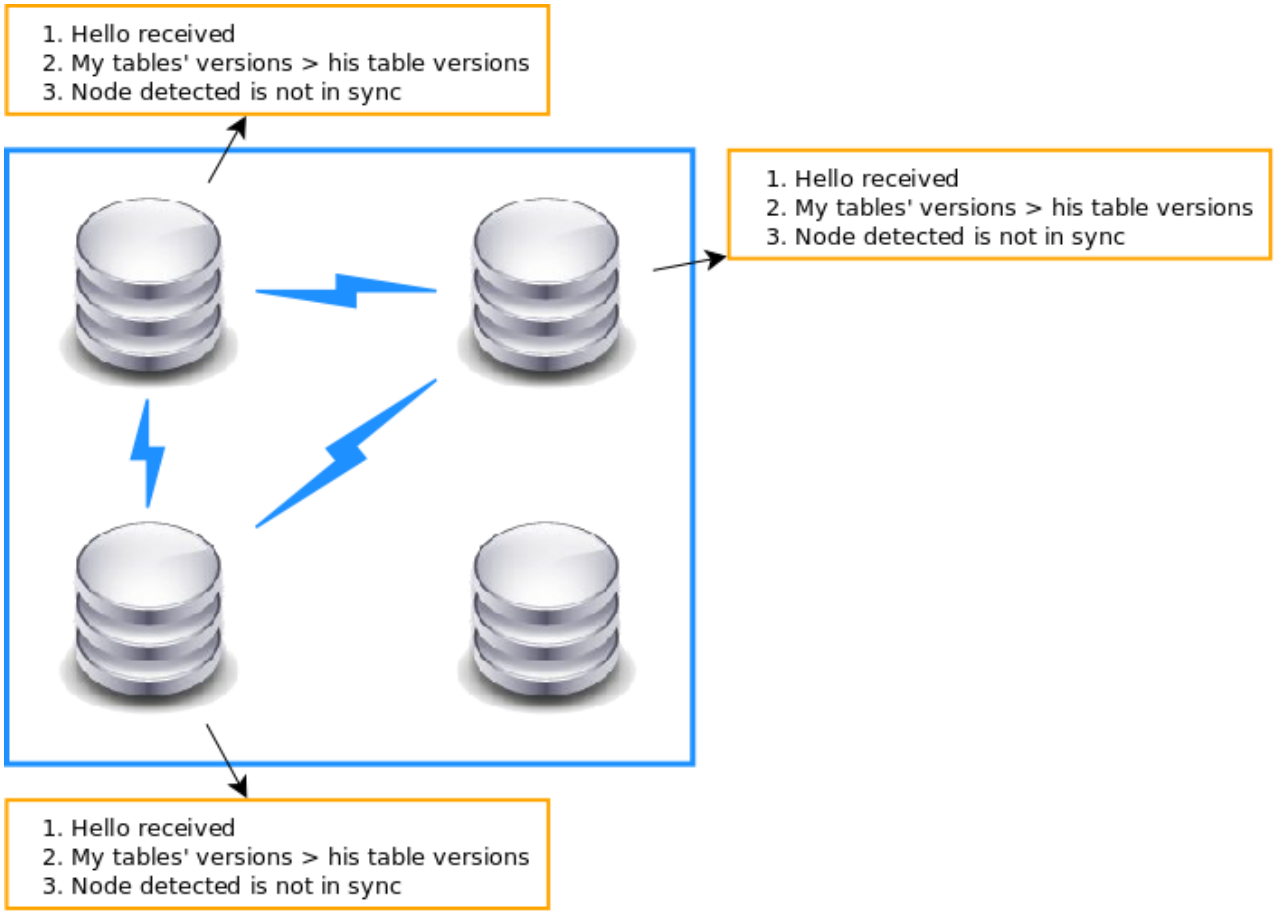

Rysunek 4.3: Obecne węzły porównują tabele w pakiecie Hello z własnymi wersjami i stwierdzają, że konieczna jest synchronizacja

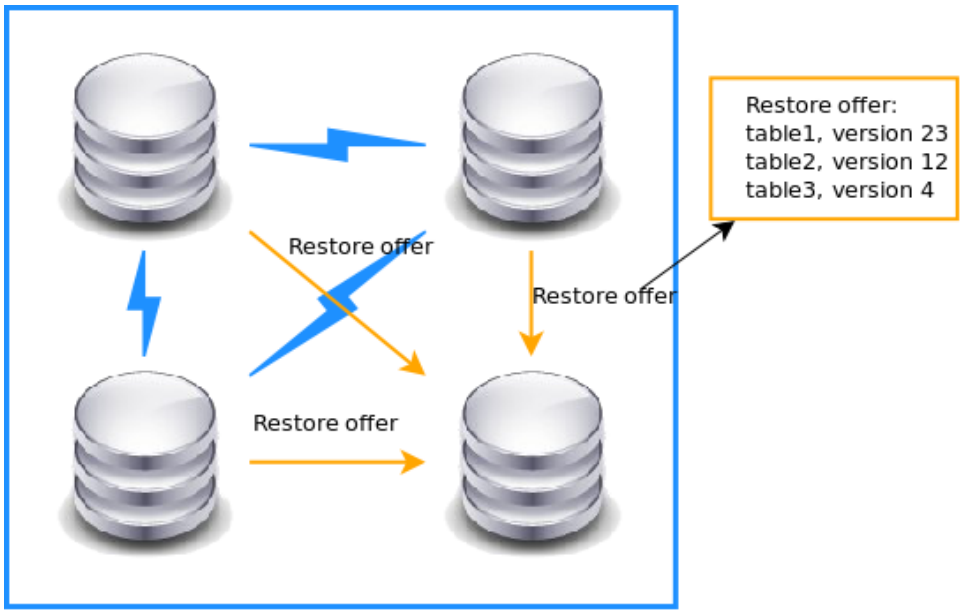

Rysunek 4.4: Węzły blokują odpowiednie obszary danych, a gdy ich listy prowadzonych sesji będą puste, wysyłana jest oferta synchronizacji

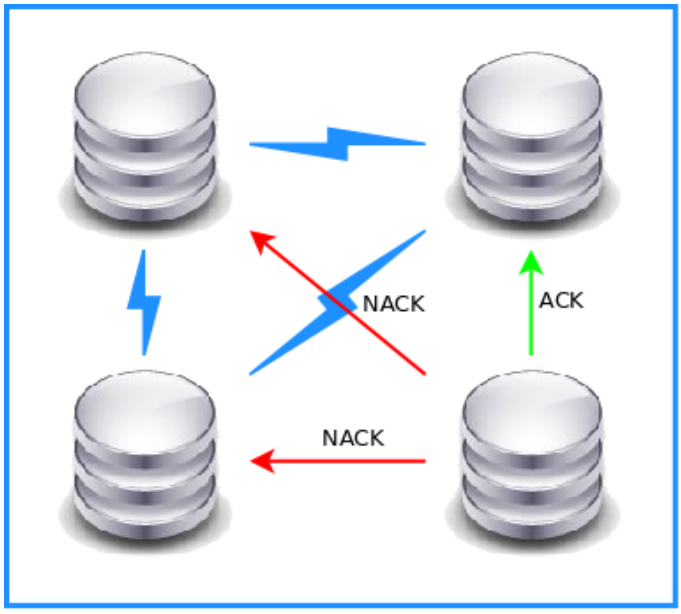

Rysunek 4.5: Nowy węzeł wybiera jeden z węzłów do synchronizacji, pozostałe odrzuca

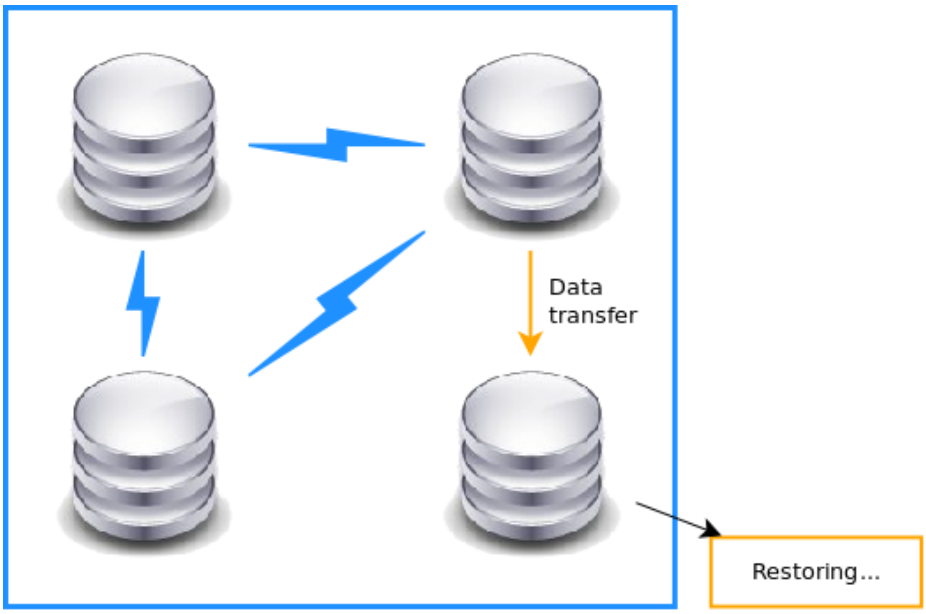

Rysunek 4.6: Następuje transfer tabel i synchronizacja danych

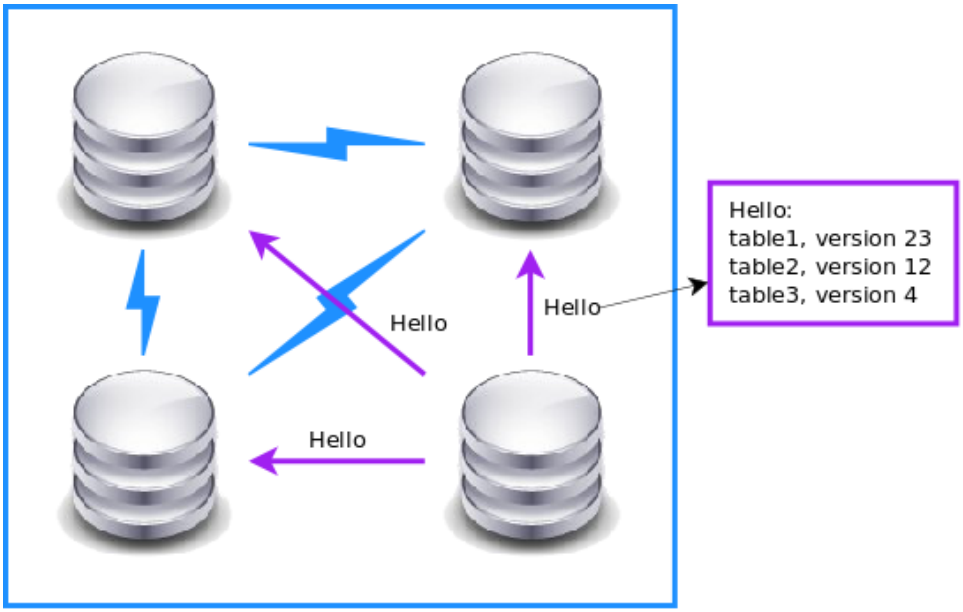

Rysunek 4.7: Po synchronizacji węzeł będzie wysyłał już hello z poprawnymi wersjami tabel

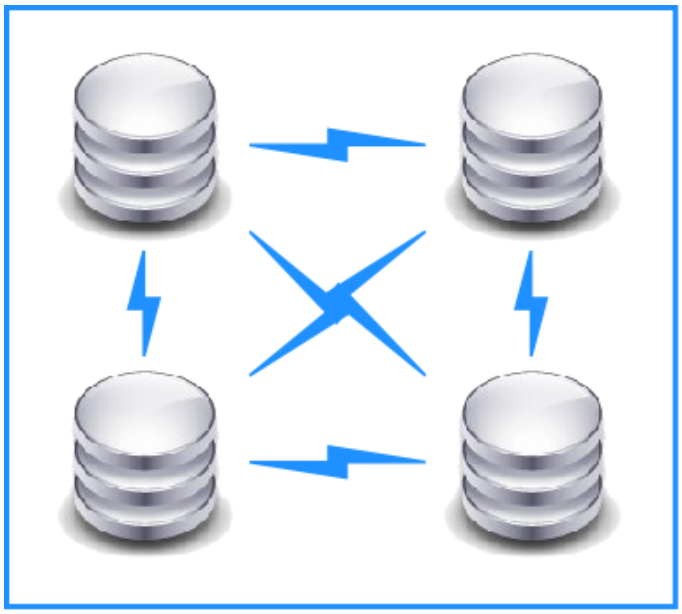

Rysunek 4.8: Ostatecznie zostanie uznany za zsynchronizowany i włączony do struktury

Rozdział 5

Diagramy sekwencji

5.1 Wiadomości

Poniżej zaprezentowane zostały diagramy sekwencji wywołań metod w klasach używanych do trójfazowego zatwierdzania transakcji. Aby wszystkie diagramy były zrozumiane na początku zaprezentowano hierarchię klas dla TPC oraz przedstawiające hierarchie klas stanów Coordinatora i Cohort'a.

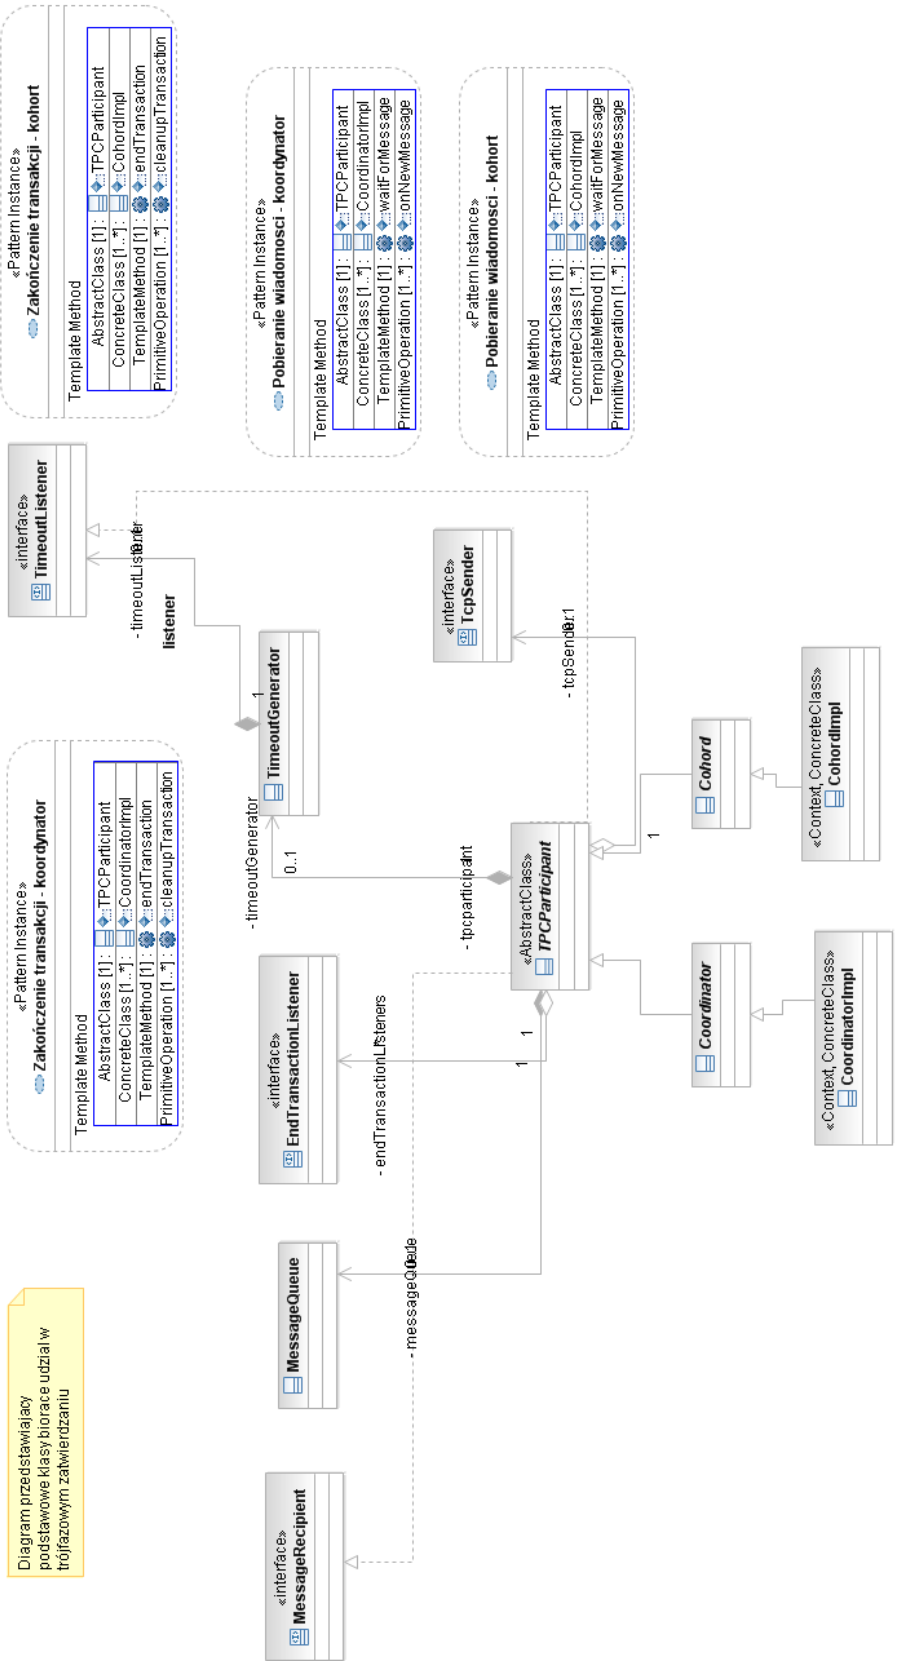

Rysunek 5.1: Ogólna hierarchia klas dla TPC

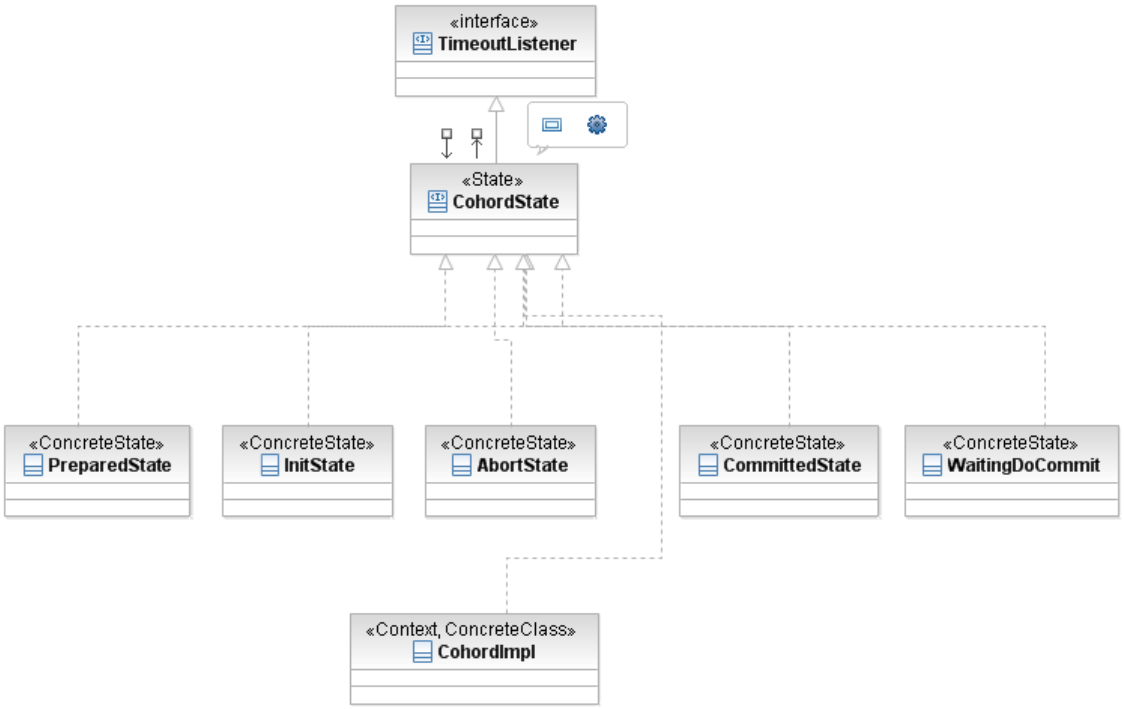

Rysunek 5.2: Hierarchia klas dla Cohort

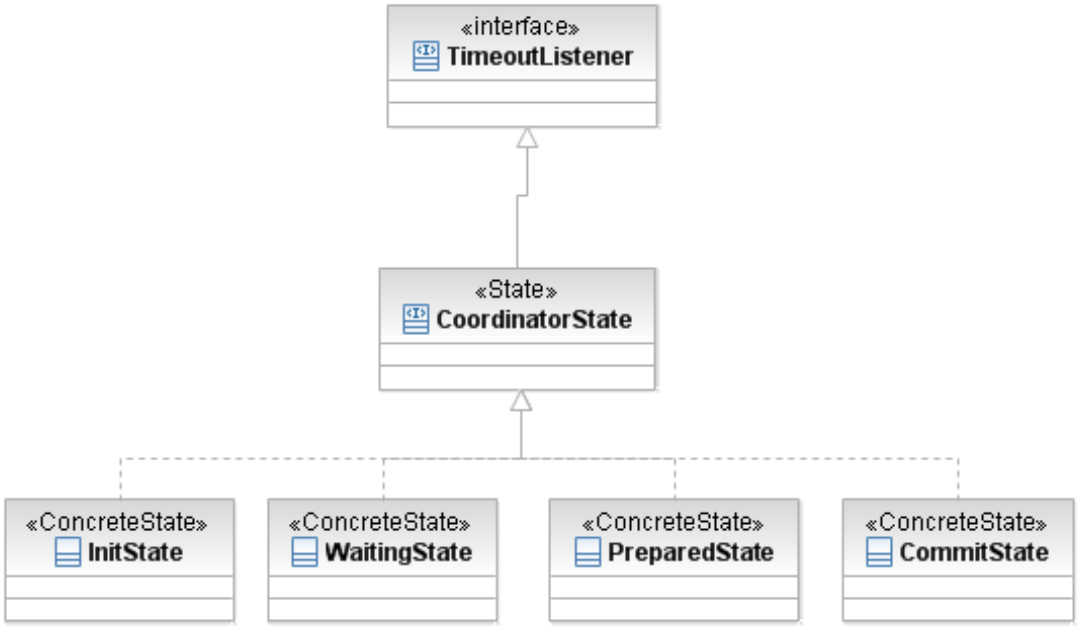

Rysunek 5.3: Hierarchia klas dla Coordinator

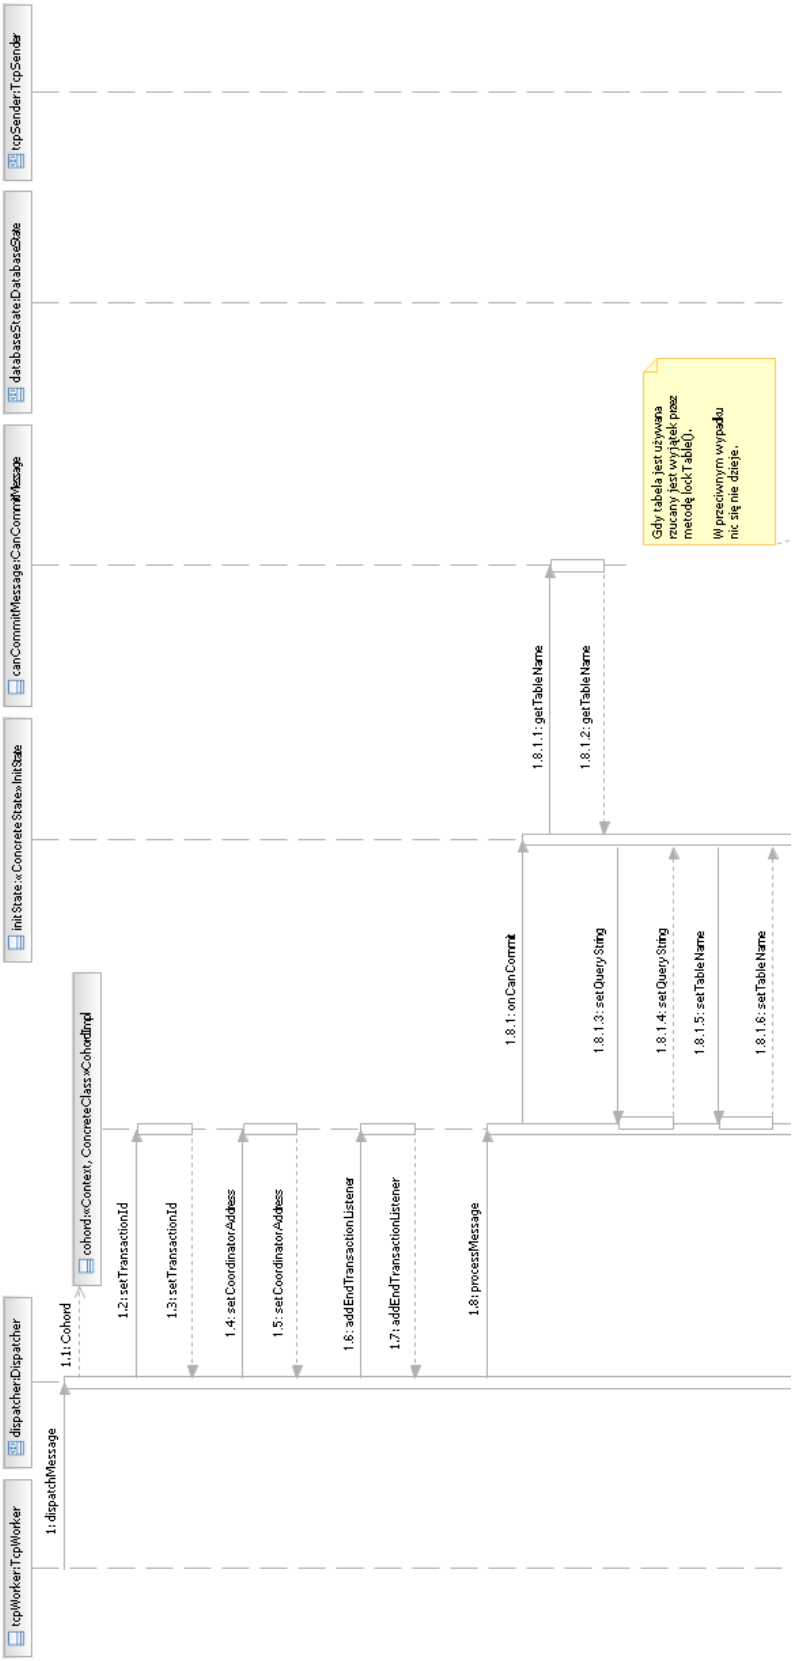

Rysunek 5.4: Obsługa wiadomości CanCommit - cz. 1

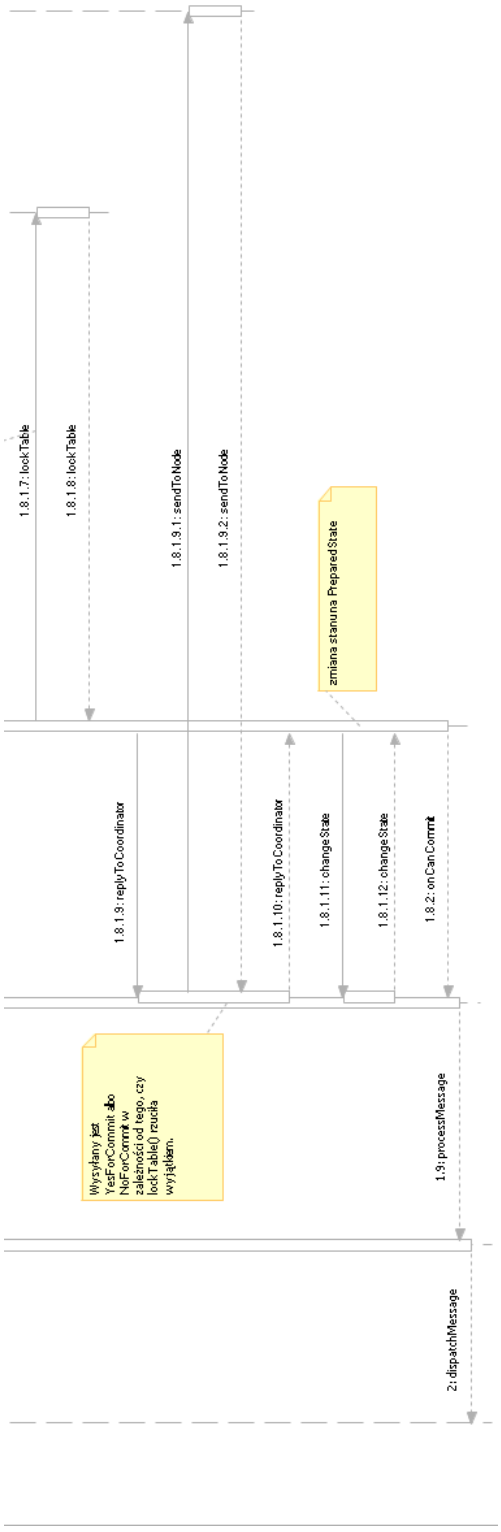

Rysunek 5.5: Obsługa wiadomości CanCommit - cz. 1

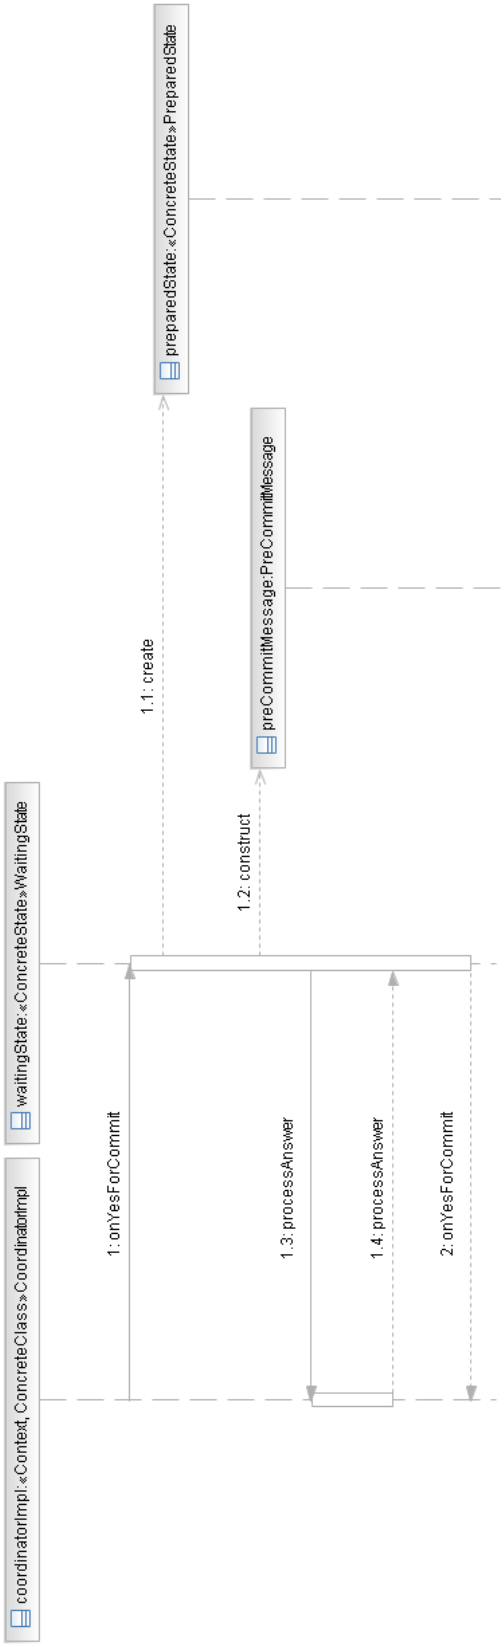

Rysunek 5.6: Obsługa wiadomości YesForCommit

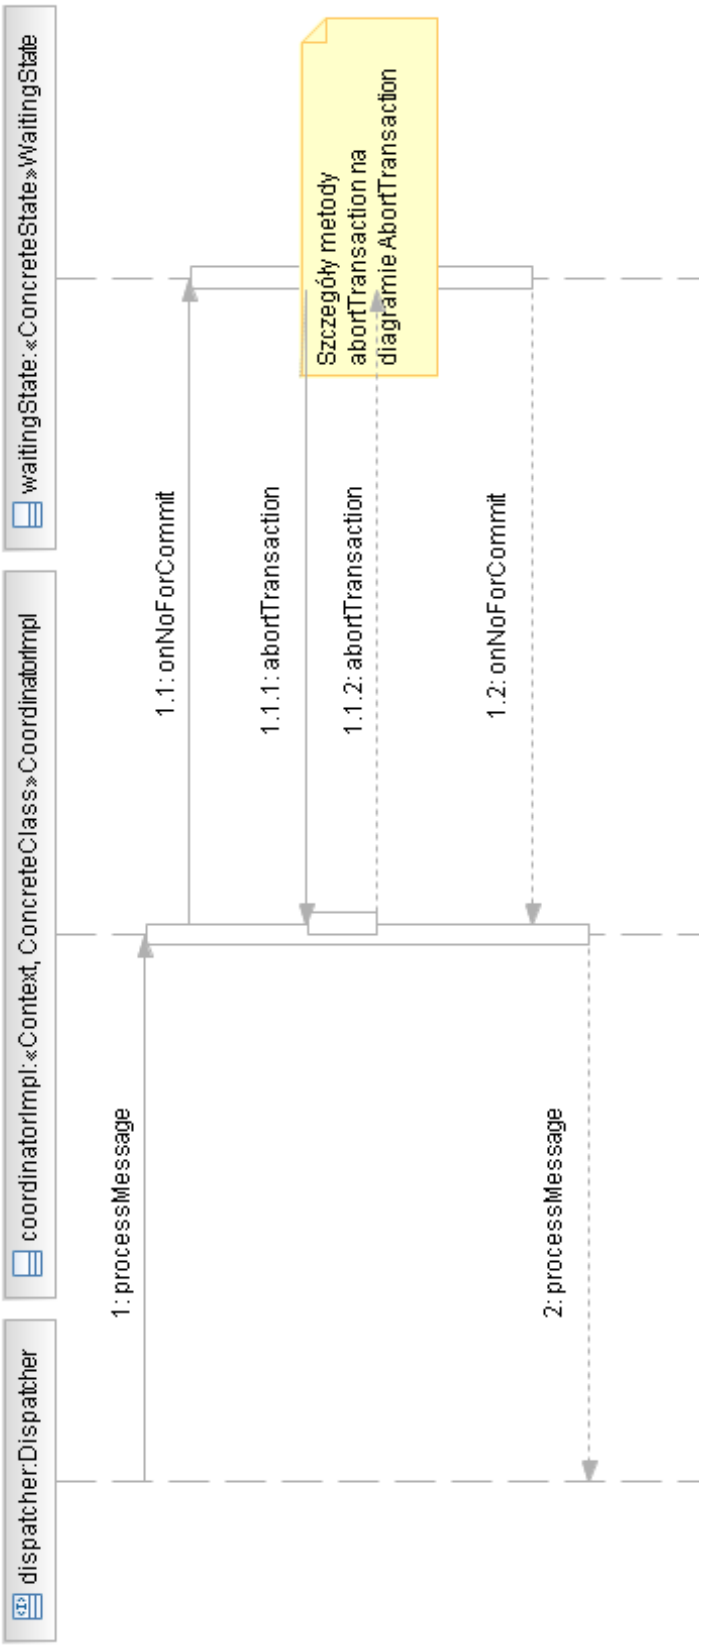

Rysunek 5.7: Obsługa wiadomości NoForCommit

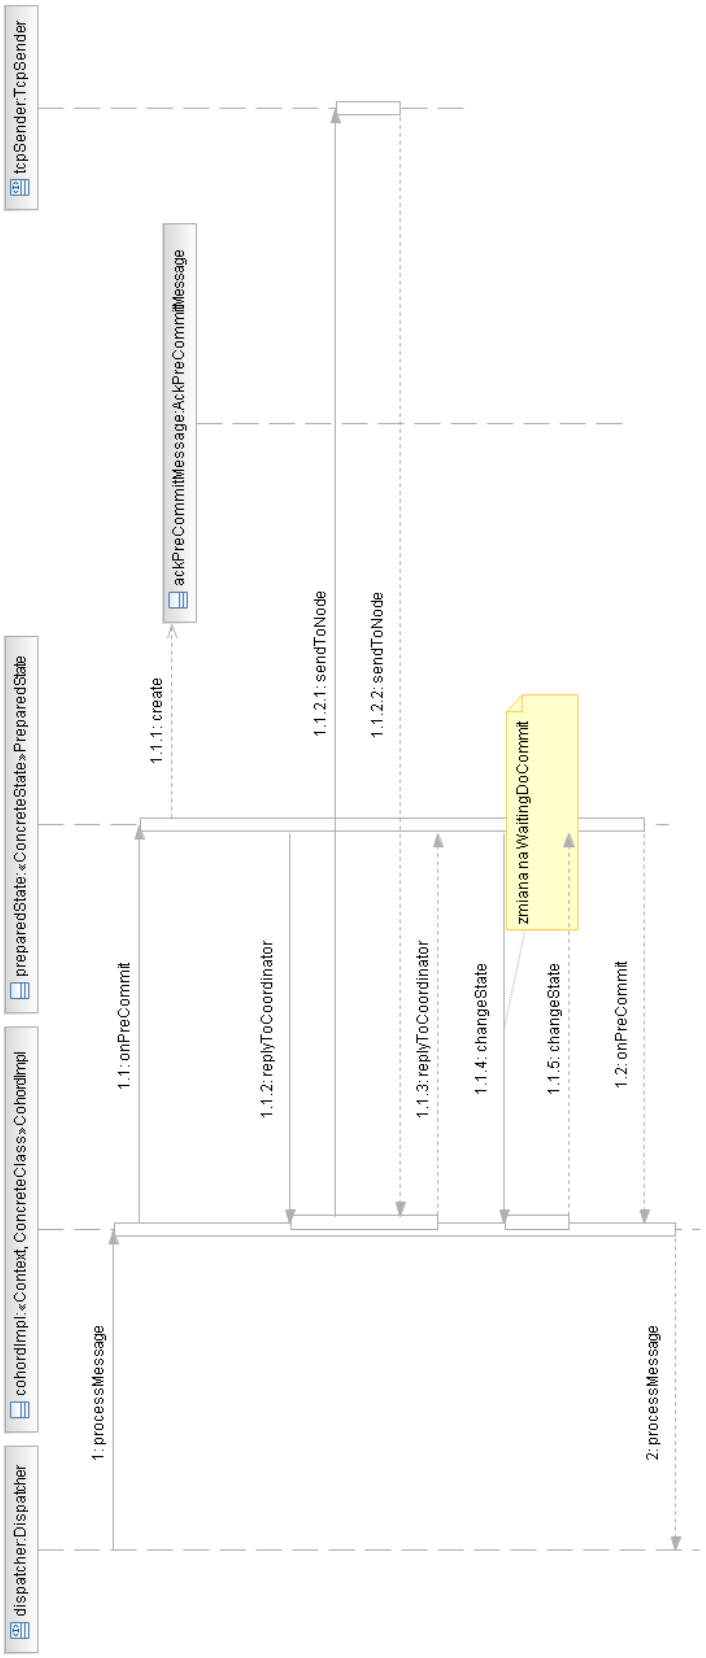

Rysunek 5.8: Obsługa wiadomości PreCommit

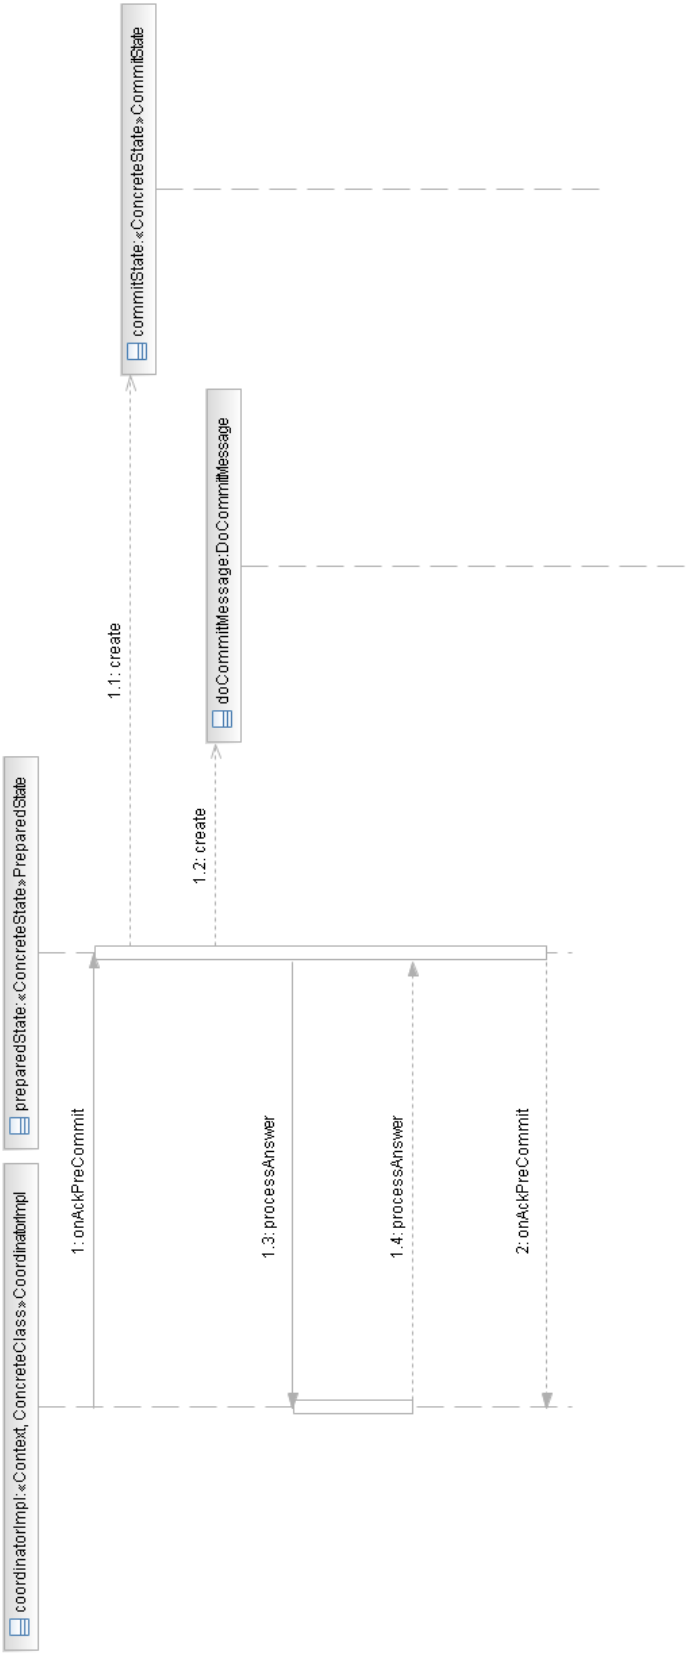

Rysunek 5.9: Obsługa wiadomości AckPreCommit

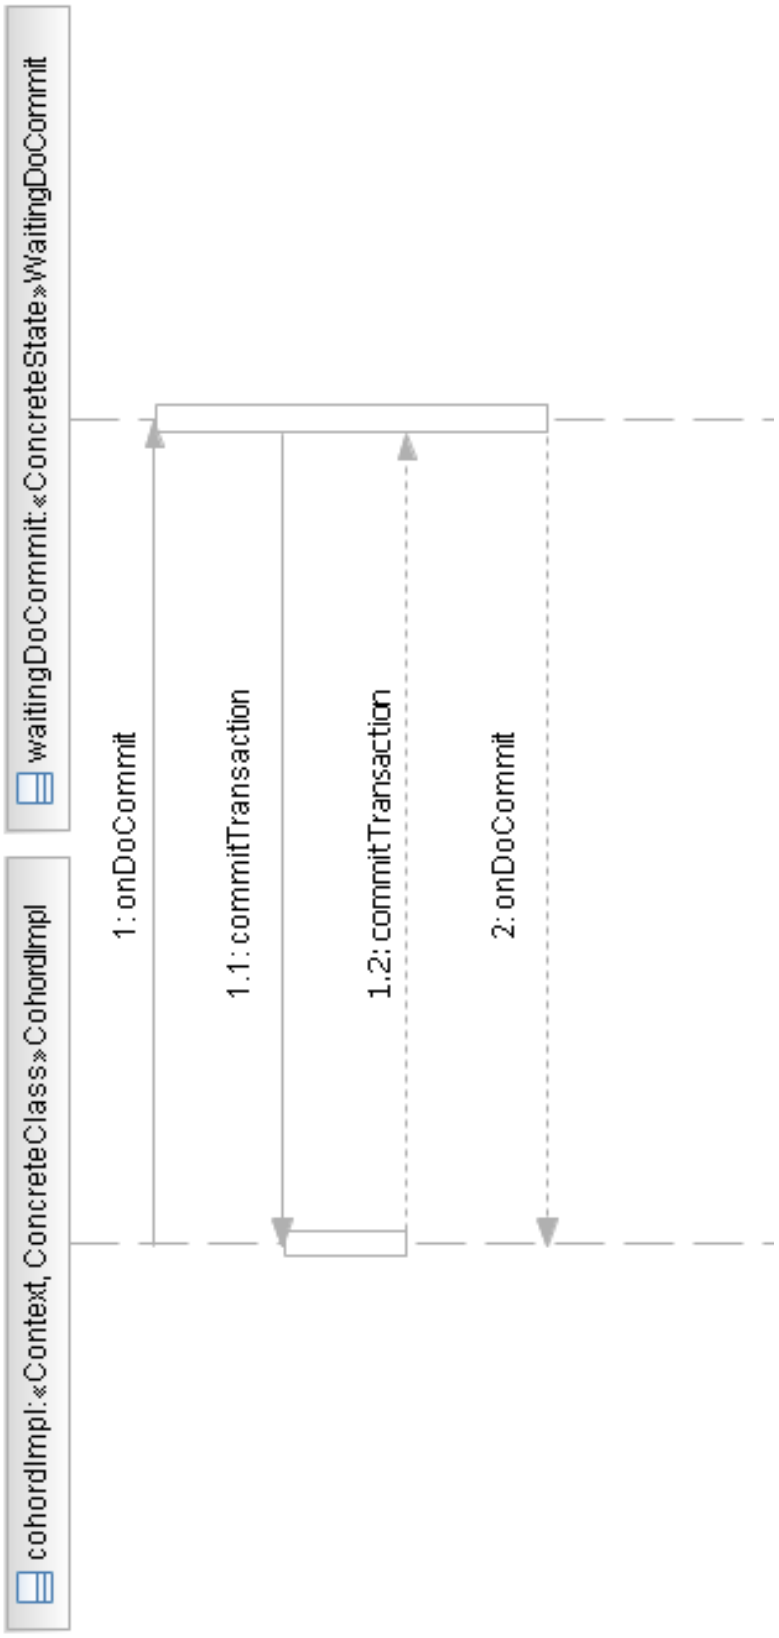

Rysunek 5.10: Obsługa wiadomości DoCommit

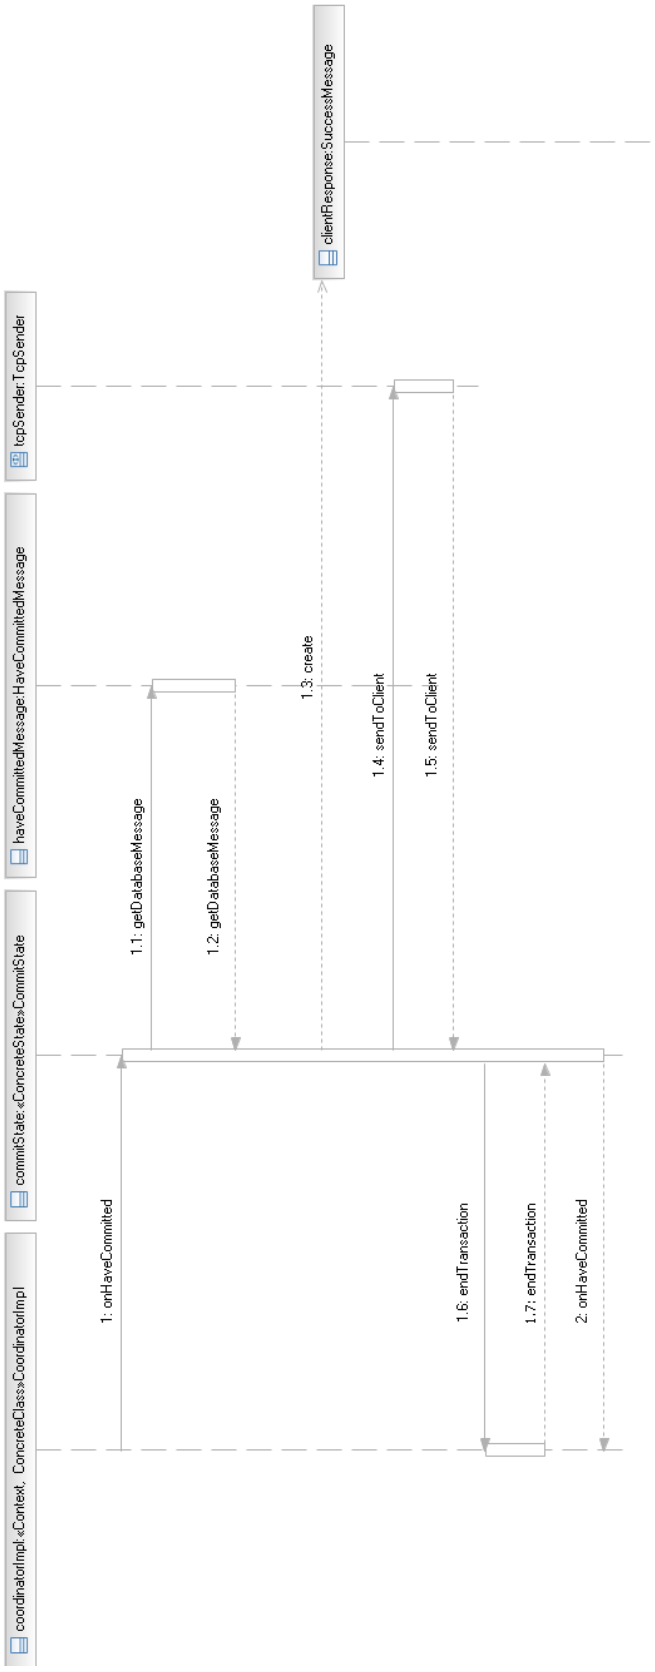

Rysunek 5.11: Obsługa wiadomości HaveCommitted